Classificação de espécies de Iris com KNN

Relatório da atividade avaliativa — Aula 7: K-Vizinhos Mais Próximos
Mineração de Dados — Análise e Desenvolvimento de Sistemas — Profa. Ana Paula
Aluno(a): _____ | 23/10/2026

1. Objetivo e dados

Classificar a espécie de flores de Iris com KNN. A base tem 150 flores e 3 espécies (setosa, versicolor e virginica), com 50 de cada. A classe-alvo é a espécie, e os quatro atributos são medidas em centímetros:

Atributo	Significado	Média (cm)	Desvio (cm)
sepal length (cm)	comprimento da sépala	5,84	0,83
sepal width (cm)	largura da sépala	3,06	0,44
petal length (cm)	comprimento da pétala	3,76	1,77
petal width (cm)	largura da pétala	1,20	0,76

Tabela 1. Atributos da base Iris.

2. Método

- Divisão de 75% para treino (112 flores) e 25% para teste (38 flores), com `random_state=123` e `stratify=y`.
- `Pipeline` com `StandardScaler` e `KNeighborsClassifier`.
- Validação cruzada estratificada de 5 folds, **só no treino**, para escolher K (1, 3, 5, 7, 9, 11 e 15), o peso (uniforme ou por distância) e a distância (euclidiana ou Manhattan).
- Avaliação do modelo escolhido **uma única vez** no teste.
- Árvore de Decisão no mesmo particionamento, com `max_depth` escolhido pela mesma validação cruzada.

3. Resultados

K	Acurácia de treino
1	1,000
3	0,946
5	0,955
7	0,955
9	0,955
11	0,955
15	0,946

Tabela 2. Acurácia de treino por K (pesos uniformes, euclidiana).

A validação cruzada escolheu **K=15, peso por distância e distância euclidiana**, com acurácia média de **0,956**. No teste, o modelo acertou **37 de 38 flores (acurácia 0,974)**. Erros: 1 versicolor prevista como virginica.

Classe	Precisão	Recall	F1-score	Flores
setosa	1,000	1,000	1,000	12
versicolor	1,000	0,923	0,960	13
virginica	0,929	1,000	0,963	13
média macro	0,976	0,974	0,974	38

Tabela 3. Métricas do KNN no teste (38 flores).

K	uniforme + euclidiana	distância + euclidiana	uniforme + Manhattan	distância + Manhattan
1	0,920	0,920	0,910	0,910
3	0,946	0,946	0,938	0,938
5	0,938	0,947	0,946	0,946
7	0,947	0,947	0,955	0,955
9	0,946	0,947	0,947	0,947
11	0,938	0,947	0,955	0,955
15	0,929	0,956	0,938	0,946

Tabela 4. Acurácia média na validação cruzada por K, peso e distância.

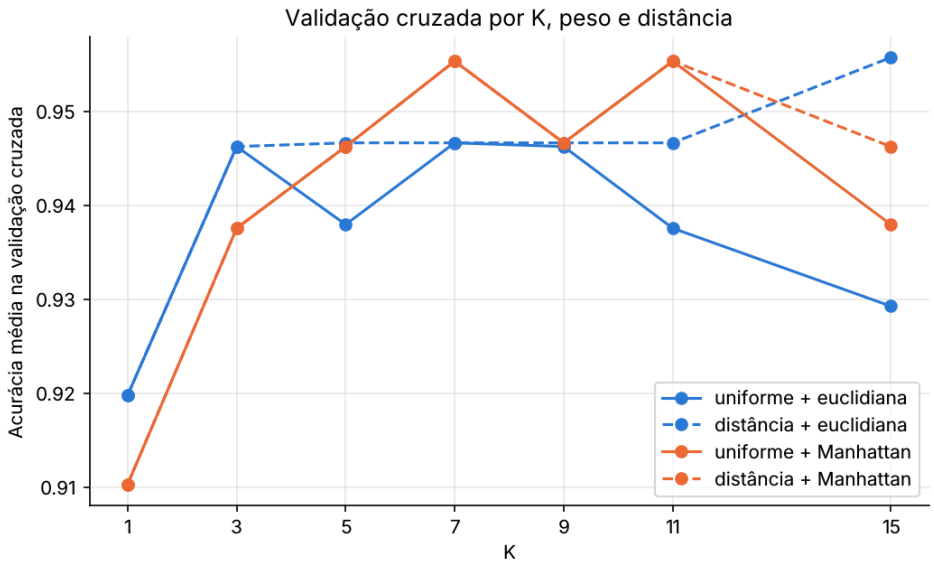


Figura 1. Acurácia de validação cruzada por K, peso e distância.

Modelo	Parâmetros escolhidos	Acurácia validação	Acurácia teste	Acertos no teste
KNN	K=15, peso por distância, euclidiana	0,956	0,974	37 de 38
Árvore de Decisão	max_depth=3	0,946	0,921	35 de 38

Tabela 5. KNN × Árvore de Decisão.

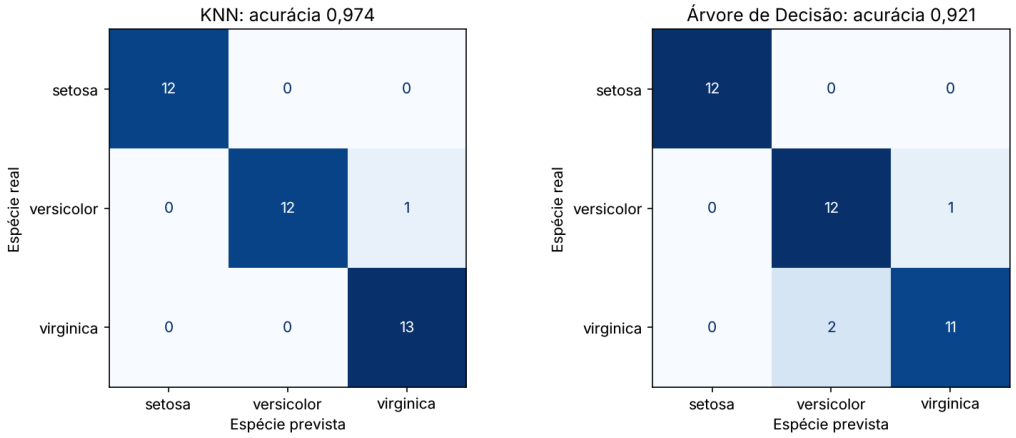


Figura 2. Matrizes de confusão no teste.

4. Conclusão

- **Desempenho:** o KNN escolhido (K=15, peso por distância, euclidiana) obteve 0,956 na validação e 0,974 no teste (37 de 38), com precisão, recall e F1 macro de 0,976, 0,974 e 0,974. Erros: 1 versicolor prevista como virginica.

- **Sensibilidade a K:** com K=1 a acurácia de treino é 1,000, porque cada flor é vizinha de si mesma e o modelo memoriza. De K=3 a K=15, a melhor validação de cada K fica entre 0,946 e 0,956, então vários valores de K são equivalentes.
- **Pesos e distância:** o peso por distância nunca piorou a validação e ajudou mais com K grande (em K=15, 0,956 contra 0,929 com peso uniforme, na euclidiana). Entre euclidiana e Manhattan não houve vencedor fixo.
- **Normalização:** as quatro medidas estão em cm e têm escalas parecidas (desvio de 0,44 a 1,77 cm), então a padronização pesa menos aqui do que em bases com unidades diferentes. Ela fica dentro do pipeline para que nenhum atributo domine a distância e para ser ajustada só com o treino.
- **KNN × Árvore:** a árvore (max_depth=3) acertou 35 de 38 (0,921). A diferença para o KNN é de 2 flores, pequena demais para afirmar que um algoritmo é superior.
- **Limitações e generalização:** o teste tem só 38 flores (cada uma vale 2,6 pontos), e a Iris é pequena, limpa e balanceada, um cenário favorável ao KNN. O KNN também guarda todo o treino e calcula distâncias a cada previsão, o que fica caro em bases grandes. A proximidade entre validação (0,956) e teste (0,974) indica boa generalização para flores da mesma população, mas o número exato depende do sorteio treino/teste.