Classificação de espécies de Iris com KNN

Relatório da atividade avaliativa — Aula 7: K-Vizinhos Mais Próximos
Mineração de Dados — Análise e Desenvolvimento de Sistemas — Profa. Ana Paula
Aluno(a): _____ | Gerado em 23/10/2026

1. Objetivo

Classificar a espécie de flores de Iris a partir de quatro medidas, usando o algoritmo K-Vizinhos Mais Próximos (KNN), escolhendo seus hiperparâmetros de forma reproduzível e sem usar o conjunto de teste, e comparando o resultado com uma Árvore de Decisão. O relatório resume o experimento do notebook *Aula7_KNN_resolvido.ipynb* (Atividade 11); todos os números abaixo são lidos dos arquivos gerados por ele.

2. Dados

A base Iris tem **150 flores** e **3 espécies** (setosa, versicolor e virginica), com 50 flores de cada — uma base balanceada. Os quatro atributos são medidas em centímetros da **sépala** (folhas externas, que protegem o botão) e da **pétala** (folhas internas, coloridas). A classe-alvo é a espécie.

Atributo	Significado	Média setosa	Média versicolor	Média virginica
sepal length (cm)	comprimento da sépala	5,01	5,94	6,59
sepal width (cm)	largura da sépala	3,43	2,77	2,97
petal length (cm)	comprimento da pétala	1,46	4,26	5,55
petal width (cm)	largura da pétala	0,25	1,33	2,03

Tabela 1. Atributos e média por espécie (cm). As medidas da pétala separam bem as espécies; as da sépala se sobrepõem.

3. Método

- **Divisão:** 75% treino (112 flores) e 25% teste (38 flores), com `random_state=123` e `stratify=y`.
- **Modelo:** `Pipeline(StandardScaler, KNeighborsClassifier)`. O padronizador fica dentro do pipeline, então só aprende média e desvio com o treino.
- **Escolha dos parâmetros:** `GridSearchCV` com validação cruzada estratificada de 5 folds **apenas no treino**, testando K = 1, 3, 5, 7, 9, 11 e 15, pesos uniformes ou por distância e distância euclidiana ou Manhattan (28 combinações).
- **Avaliação:** o modelo escolhido é avaliado **uma única vez** no teste (acurácia, precisão, recall, F1 e matriz de confusão).
- **Comparação:** Árvore de Decisão com `max_depth` escolhido pela mesma validação cruzada, no mesmo particionamento.
- **Robustez:** o procedimento inteiro (escolha + teste) repetido em 30 sorteios estratificados de treino e teste.

4. Resultados

4.1 Sensibilidade a K

K	Acurácia de treino	Validação cruzada (média)	Validação cruzada (desvio)
1	1,000	0,920	0,034
3	0,946	0,946	0,052
5	0,955	0,938	0,045
7	0,955	0,947	0,033
9	0,955	0,946	0,034
11	0,955	0,938	0,036
15	0,946	0,929	0,044

Tabela 2. KNN com pesos uniformes e distância euclidiana. A validação usa só o treino.

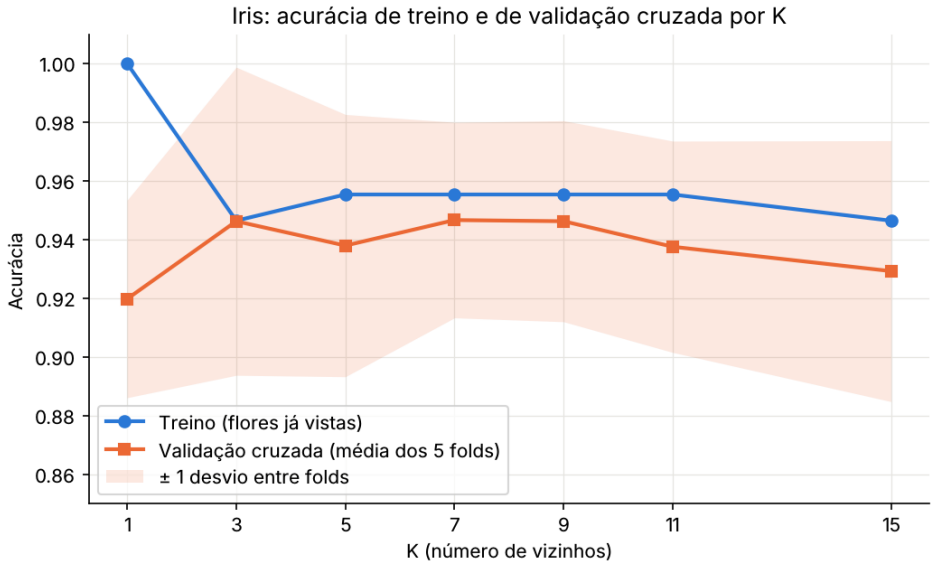


Figura 1. Acurácia de treino e de validação cruzada por K. A faixa clara é ±1 desvio-padrão entre os 5 folds.

Com K=1 a acurácia de treino é 1,000: cada flor é a vizinha mais próxima de si mesma, então o modelo apenas memoriza. É também o K com a pior validação (0,920). Para K de 3 a 15 a validação fica entre 0,929 e 0,947, uma variação menor que o desvio entre os folds (0,03 a 0,05): a curva é praticamente plana.

4.2 Modelo escolhido e avaliação no teste

A validação cruzada escolheu **K=15, peso proporcional à distância e distância euclidiana**, com acurácia média de **0,956** (desvio 0,028). A escolha é apertada: 5 das 28 combinações ficam a menos de 0,001 da melhor. No teste, o modelo acertou **37 de 38 flores (acurácia 0,974)**, com precisão, recall e F1 macro de 0,976, 0,974 e 0,974. Erros: 1 versicolor prevista como virginica (matriz de confusão na Figura 3).

Classe	Precisão	Recall	F1-score	Flores
setosa	1,000	1,000	1,000	12
versicolor	1,000	0,923	0,960	13
virginica	0,929	1,000	0,963	13
média macro	0,976	0,974	0,974	38
média ponderada	0,976	0,974	0,974	38

Tabela 3. Métricas do KNN escolhido no teste (38 flores).

A acurácia de treino desse modelo é 1,000, mas isso **não** indica memorização: com pesos por distância, cada flor de treino está a distância zero de si mesma e recebe peso máximo, então a acurácia de treino é sempre 1. Nesse caso, a validação cruzada é o indicador que importa.

4.3 Pesos e métrica de distância

K	uniforme + euclidiana	distância + euclidiana	uniforme + Manhattan	distância + Manhattan
1	0,920	0,920	0,910	0,910
3	0,946	0,946	0,938	0,938
5	0,938	0,947	0,946	0,946
7	0,947	0,947	0,955	0,955
9	0,946	0,947	0,947	0,947
11	0,938	0,947	0,955	0,955
15	0,929	0,956	0,938	0,946

Tabela 4. Acurácia média de validação cruzada para cada combinação.

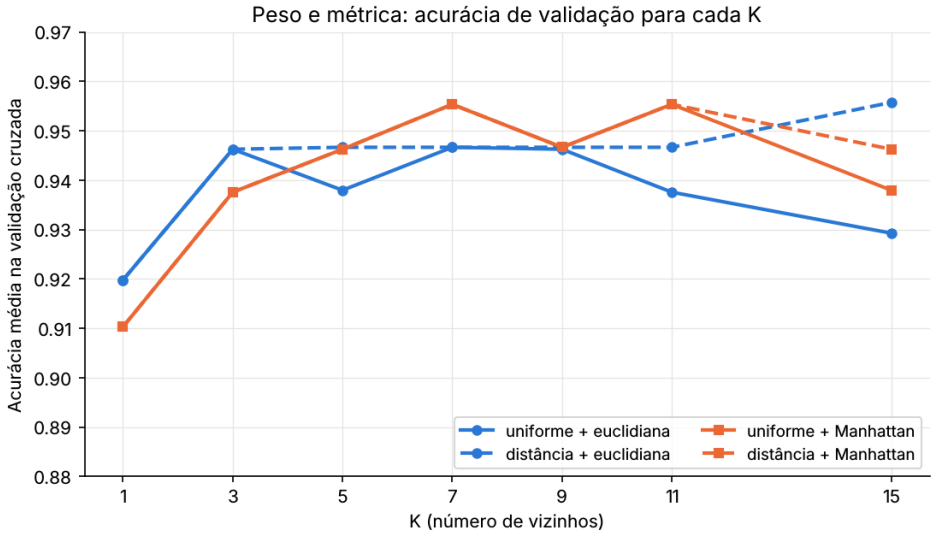


Figura 2. As quatro combinações de peso e métrica por K (onde as linhas se sobrepõem, os resultados são iguais).

Em média, o peso por distância ficou **+0,4 ponto** em relação ao uniforme e nunca piorou a validação, com o maior ganho (+2,6 pontos) com K grande, quando vizinhos distantes passariam a votar com o mesmo peso dos próximos. Entre euclidiana e Manhattan a diferença média foi de −0,1 ponto, variando de −1,8 a +0,9 conforme K, sem vencedor fixo. Na média dos folds, cada flor vale cerca de 0,9 ponto, então essas diferenças correspondem a poucas flores.

4.4 Comparação com a Árvore de Decisão

Modelo	Configuração	Papel	Validação (média ± desvio)	Treino	Teste
KNN	K=5, uniforme, euclidiana (exemplo da seção 7.1)	referência	0,938 ± 0,045	0,955	0,947
KNN	K=15, distância, euclidiana	escolhido pela validação	0,956 ± 0,028	1,000	0,974
KNN	uniforme + euclidiana, melhor K=7	variante (só validação)	0,947 ± 0,033	—	—
KNN	distância + euclidiana, melhor K=15	variante (só validação)	0,956 ± 0,028	—	—
KNN	uniforme + Manhattan, melhor K=7	variante (só validação)	0,955 ± 0,040	—	—
KNN	distância + Manhattan, melhor K=7	variante (só validação)	0,955 ± 0,040	—	—
KNN	K=5, distância, euclidiana, sem padronização	variante (só validação)	0,955	—	—
Árvore de Decisão	max_depth=3	escolhida pela validação	0,946 ± 0,033	0,964	0,921
Árvore de Decisão	sem limite de profundidade (profundidade 6)	referência	0,937 ± 0,036	1,000	0,974

Tabela 5. Resultados reunidos. Linhas destacadas: modelos escolhidos pela validação. Só os modelos escolhidos e as referências foram avaliados no teste.

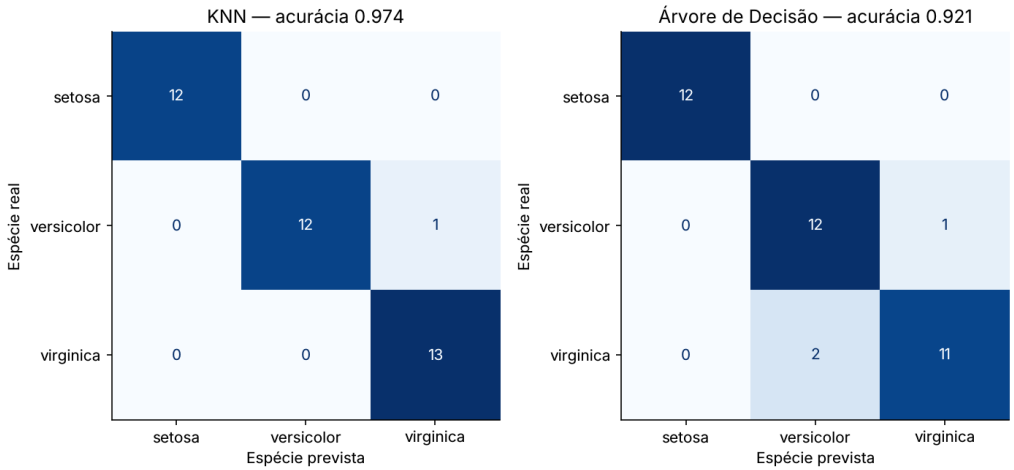


Figura 3. Matrizes de confusão no teste: KNN escolhido e Árvore de Decisão escolhida.

A árvore escolhida pela validação (`max_depth`=3, validação 0,946) acertou **35 de 38** flores (acurácia 0,921), com erros também na fronteira versicolor × virginica, e usa quase só o atributo *petal length (cm)* (importância 0,972). A diferença para o KNN é de 2 flores, ou 5,3 pontos. Ela não é robusta: a árvore sem limite de profundidade, que a validação não escolheu, teria acurácia de teste 0,974.

4.5 Generalização em outros sorteios

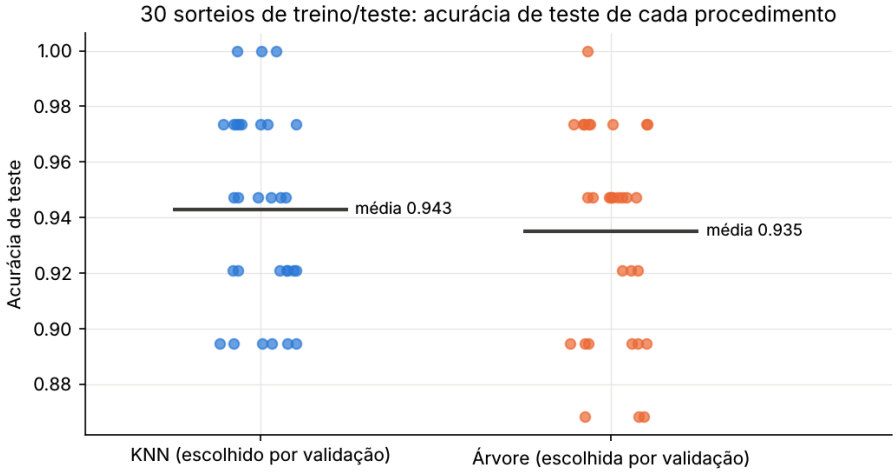


Figura 4. Acurácia de teste do procedimento completo em 30 sorteios de treino/teste.

Repetindo o procedimento completo em 30 sorteios, o KNN teve acurácia média de **0,943** (desvio 0,035) e a árvore **0,935** (desvio 0,038). O KNN foi melhor em 12 sorteios, a árvore em 6 e houve empate em 12. O K escolhido também mudou de um sorteio para outro: K=5 em 11 deles, e os demais espalhados por K=1, K=3, K=7, K=9, K=11 e K=15.

5. Conclusão

- **Desempenho.** O KNN classificou a Iris muito bem: validação de 0,956 e 37 de 38 flores certas no teste. A setosa é trivial; todos os erros ficam na fronteira versicolor × virginica, que se sobrepõem nas medidas.
- **Sensibilidade a K.** K=1 memoriza o treino e valida pior; de K=3 em diante a validação é praticamente plana, com diferenças menores que a variação entre folds. Não existe um “K certo” para a Iris, e sim uma faixa de valores razoáveis — tanto que a validação escolheu Ks diferentes em sorteios diferentes.
- **Normalização.** Na Iris a padronização não foi decisiva, porque os quatro atributos estão em centímetros e em escalas parecidas. No K escolhido ela ajudou (0,956 com × 0,938 sem), mas com K=1, 5 e 7 a versão sem padronização foi melhor e com K=3, 9 e 11 houve empate. Ainda assim, padronizar dentro do pipeline é a escolha segura: quando as escalas são muito diferentes (como no exemplo sintético da aula, com um atributo multiplicado por 1000), a falta dela derruba a acurácia.

- **Limitações.** O teste tem só 38 flores, então cada flor vale 2,6 pontos e diferenças de uma ou duas flores não são conclusivas. A Iris é pequena, limpa, balanceada e quase separável — o cenário mais favorável ao KNN, que sofre com muitos atributos, atributos irrelevantes e ruído. O KNN também guarda toda a base de treino e calcula distâncias a cada previsão, o que fica caro em bases grandes, e não produz regras legíveis como a árvore.
- **Generalização.** A proximidade entre validação (0,956) e teste (0,974), e a média de 0,943 em 30 sorteios, indicam que o modelo generaliza bem para flores da mesma população. O número mais honesto a relatar não é a acurácia de um único sorteio, e sim algo em torno de 0,94, com variação de cerca de ±3 pontos. A vantagem média sobre a árvore existe, mas é menor que a variação entre sorteios.

6. Reprodutibilidade

Sementes fixas (`random_state=123` na divisão, na validação cruzada e na árvore; sorteios de robustez com `random_state` de 0 a 29). Para refazer: execute *Aula7_KNN_resolvido.ipynb* do início ao fim (ele grava *figuras/* e *resultados/*) e depois `python gerar_relatorio.py`. Referências: CASTRO e FERRARI, *Introdução à mineração de dados* (Saraiva, 2016), cap. 5, seção 5.3.1; documentação do Scikit-learn (Nearest Neighbors, KNeighborsClassifier, Pipeline).